Лабораторная работа №2. Задание 1.

Характеристики вычислительного узла

- **Наименование сервера:** ProLiant XL270d Gen10
- **Модель CPU:** Intel(R) Xeon(R) Gold 6248 CPU @ 2.50GHz (2 сокета, 20 ядер на сокет, 80 потоков(HT))
- **NUMA узлы:** 2 узла (Node 0: CPU 0-19, 40-59; Node 1: CPU 20-39, 60-79)
- **Оперативная память (RAM):**
  - Node 0: ~376 GB
  - Node 1: ~377 GB
  - Итого: ~753 GB
- **Операционная система:** Ubuntu 22.04.5 LTS

Анализ масштабируемости

Замеры проводились на массивах размером `20000x20000` и `40000x40000`. Ускорение $S(p)$ вычислялось по формуле: $S(p) = \frac{T_1}{T_p}$, где T_1 - время последовательного выполнения (на 1 потоке), а T_p - время выполнения на p потоках.

Согласно заданию, время измеряется **только** для основной вычислительной фазы (без учета времени, затраченного на инициализацию массивов).

Кол-во потоков	Время (20000^2), с	Ускорение $S(p)$	Время (40000^2), с	Ускорение $S(p)$
1	1.284710	1.00	6.221484	1.00
2	0.685136	1.88	4.118782	1.51
4	0.319801	4.02	1.706965	3.64
7	0.193153	6.65	0.915792	6.79
8	0.165974	7.74	0.683131	9.11
16	0.086106	14.92	0.324849	19.15
20	0.067321	19.08	0.267043	23.30
40	0.037416	34.34	0.267401	23.27

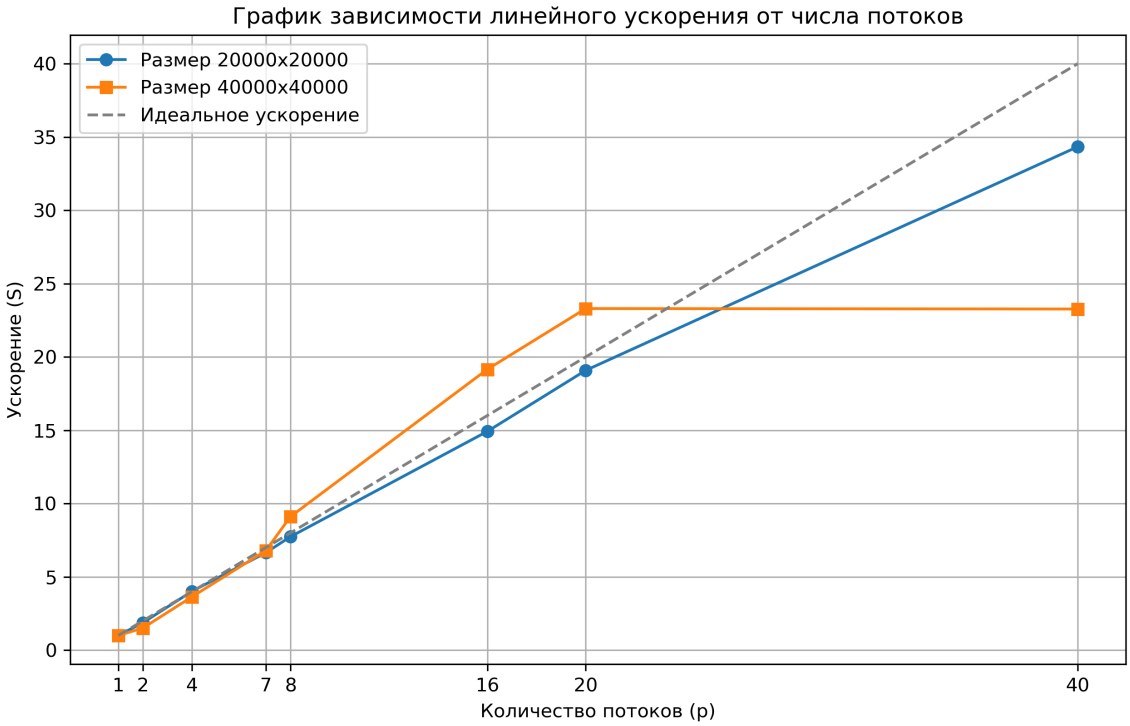

Выводы

1. Для матрицы меньшего размера (20000×20000) на большом числе потоков ускорение растет почти линейно (~34.3x на 40 потоках).
2. Для большей матрицы 40000×40000 ускорение уверенно растет вплоть до 20 потоков, после чего прекращает расти. Это явный признак того, что программа уперлась в **пропускную способность памяти**.

Дополнительное задание: Привязка потоков

Для проверки влияния локальности данных и пропускной способности памяти был проведен тест с жесткой привязкой 20 потоков к физическим ядрам первого сокета (NUMA Node 0). Для привязки использовалась утилита `taskset`.

Результаты на 20 потоках:

Размер матрицы	Без привязки	С привязкой (только Node 0)
20000 x 20000	0.086056 с	0.110726 с
40000 x 40000	0.290094 с	0.372787 с

Вывод по привязке

При жесткой привязке к ядрам одной NUMA-ноды программа стала работать **медленнее** (примерно на 30%). Это происходит потому, что:

- Когда программа работает **без привязки**, 20 потоков распределяются по ядрам *обоих* нодов процессора. Страницы матрицы также равномерно распределяются между планками памяти, и программа **задействует пропускную способность обеих шин памяти**.